




Про R и не только

Алексей Осипов

USE TECH


О чем митап

1. Что такое R?
2. Что такое Maple?
3. Что такое MATLAB?
4. Подробно про R




Что такое R?

- создан статистиками для статистиков
- opensource
- S => R (Ross Ihaka, Robert Gentleman)
- интерпретируемый язык
- возможность использовать как язык общего назначения
- множество пакетов
- написан на C, Fortran и R



Особенности R

- отлично подходит для статистики
- хорошо подходит для математики
- отлично подходит для визуализации
- отлично подходит для интерпретируемого ML
- нормально подходит для ML
- можно делать сложные PoC, включая веб-приложения, пакеты, микросервисы




Примеры применения R

- продуктовая аналитика (статистические тесты, визуализация, дэшборды)
- causal inference, интерпретируемые модели
- математические модели
- opensource код для статьи
- найти приложение коду, написанному на C



Что такое Maple?

- система компьютерной алгебры
- символьные вычисления (DAGs) и не только
- коммерческое ПО
- сделано в Канаде
- интерпретируемый язык
- написан на C, Java и Maple




Особенности Maple

- незаменим для символьных вычислений
- $1/3$ это не 0.333
- может брать неопределённые интегралы
- может решать уравнения, включая дифференциальные
- можно не писать код вообще
- автоматическое построение асимптот, точек разрыва на графиках
- можно делать анимацию
- есть классы (модули)
- автоматическая параллелизация для матриц




Примеры применения Maple

- помощник учёного и инженера
- космонавтика, авиастроение
- робототехника
- физика
- биомедицина



Что такое MATLAB?

- Matrix Laboratory
- создан инженерами для инженеров
- технические вычисления
- работа с матрицами
- функции и скрипты
- коммерческое ПО
- интерпретируемый язык
- написан на C, C++, Fortran и Java




Особенности Matlab

- матрица --- базовый тип
- векторизация
- медленные циклы
- индексация с 1 (как в R и Maple)
- Simulink для визуального моделирования
- интерактивные графики
- есть классы (value и handle)
- автоматическая параллелизация при умножении матриц




Примеры применения Matlab

- наука
- моделирование физических систем
- робототехника
- аэрокосмическая и оборонная отрасли
- цифровая обработка сигналов
- финансы



Классовые системы в R

- функциональное ООП, дженерики
- S3
- S4
- R5/RC
- R6
- S7 (ex. R7)



S-классы

- S3, класс как атрибут списка
- S4, описание классов со слотами (@)
- S7/R7, классы от Hadley Wickham, описание классов со свойствами (\$ вместо @)

```
> user <- list(name = "Иван", age = 25)
> class(user) <- "User"
```

```
> setClass("UserS4",
+   slots = list(
+     name = "character",
+     age = "numeric"
+   ),
+   validity = function(object) {
+     if (object@age < 0) {
+       return("Возраст не может быть отрицательным!")
+     }
+     TRUE
+   }
+ )
```

```
> UserS7 <- new_class("UserS7",
+   properties = list(
+     name = class_character,
+     age = class_numeric
+   ),
+   validator = function(self) {
+     if (self$age < 0) {
+       "@age не может быть меньше нуля!"
+     }
+   }
+ )
```

R-классы

- R5, reference-классы, классическое ООП поверх S4, \$ и <<-
- R6, классическое ООП, \$, настоящая инкапсуляция, высокая скорость

```
> BankAccount <- setRefClass("BankAccount",  
+   fields = list(  
+     owner = "character",  
+     balance = "numeric"  
+   ),  
+   methods = list(  
+     deposit = function(amount) {  
+       balance <<- balance + amount  
+     }  
+   )  
+ )
```

```
> PersonR6 <- R6Class("PersonR6",  
+   public = list(  
+     name = NULL,  
+     initialize = function(name, age) {  
+       self$name <- name  
+       private$age <- age # Прячем возраст в частную зону  
+     },  
+     say_hello = function() {  
+       cat("Привет, меня зовут", self$name, "и мне", private$age, "лет.\n")  
+     }  
+   ),  
+   private = list(  
+     age = NULL # Извне никто не сможет написать: obj$age  
+   )  
+ )
```

data.frame

- нативная структура в R, соответствующая таблице (список векторов одной длины)
- копия при изменении
- приведение строк в факторы
- df\$age для столбца age
- aggregate, tapply
- order
- merge
- apply
- lapply, sapply

```
> agg_mean <- aggregate(salary ~ department, data = df, FUN = mean)
> names(agg_mean)[2] <- "average_salary"
> result <- agg_mean[order(-agg_mean$average_salary), ]
```

	department	average_salary
2	IT	5400
3	Sales	4350
1	HR	3650

data.table

- пакет data.table
- сверх-оптимизированный data.frame
- передача по ссылке
- fread, fwrite
- DT[i, j, by]
- := для создания столбца
- \$ для выбора столбца
- setkey для бинарного поиска
- .N, .SD
- .() как сокращение для list()
- merge

```
> result <- dt[, .(mean_salary = mean(salary)), by = department][order(-mean_salary)]
```

	department	mean_salary
1:	IT	5400
2:	Sales	4350
3:	HR	3650

tibble

- пакет dplyr
- tibble как маленькая табличка
- ленивый data.frame, с которым удобно работать
- нет преобразований строк в факторы
- нет нестрогому соответствию
- inner_join, left_join, right_join, full_join
- semi_join, anti_join
- group_by, summarize, filter, select
- mutate, arrange, relocate
- |> или %>%


```
> result <- tb_data |>
+   group_by(department) |>
+   summarise(
+     emp_count    = n(),
+     mean_salary = mean(salary)
+   ) |>
+   arrange(desc(mean_salary))
```

```
# A tibble: 3 x 3
  department emp_count mean_salary
  <chr>         <int>         <dbl>
1 IT              3             5400
2 Sales           2             4350
3 HR              2             3650
```

Графика


- ggplot2, самый известный
- plotly, rbokeh, интерактивные
- graphics, базовый R
- lattice, решётчатые графики

```
> ggplot(data = iris, aes(x = Sepal.Length, y = Sepal.Width, color = Species)) +  
+   geom_point(size = 3, alpha = 0.8) +  
+   geom_smooth(method = "lm", se = FALSE, size = 1) +  
+   labs(  
+     title = "Взаимосвязь размеров чашелистика у Ирисов",  
+     subtitle = "Разбивка по видам (Species) с линиями линейной регрессии",  
+     x = "Длина чашелистика (см)",  
+     y = "Ширина чашелистика (см)",  
+     color = "Вид ириса"  
+   ) +  
+   theme_minimal(base_size = 14) +  
+   theme(legend.position = "bottom")
```




shiny

- создание веб-приложений и дэшбордов
- деплой через shiny-сервер или в облаке
- UI, server
- реактивное программирование, reactive, observe
- множество пакетов для кастомизации
- есть способы делать десктопные shiny



R markdown

- создание интерактивных html-документов
- интерактивные таблицы
- интерактивные графики
- карты
- проблемы с большими данными
- можно вставить shiny внутрь



Статистические тесты


- сравнение средних t-тест, wilcox-test
- таблицы сопряжённости chisq.test, fisher.test
- корреляции, cor.test
- aov, anova
- binom.confint из binom (множество статистических критериев для биномиального распределения)
- ks.test
- adf.test из tseries, kpss.test

```
> binom.confint(  
+   x = successes,  
+   n = trials,  
+   conf.level = 0.95,  
+   method = "all")
```

	method	x	n	mean	lower	upper
1	agresti-coull	35	1000	0.03500000	0.02513601	0.04842287
2	asymptotic	35	1000	0.03500000	0.02360942	0.04639058
3	bayes	35	1000	0.03546454	0.02436877	0.04708812
4	cloglog	35	1000	0.03500000	0.02486801	0.04772691
5	exact	35	1000	0.03500000	0.02449753	0.04834238
6	logit	35	1000	0.03500000	0.02523342	0.04835920
7	probit	35	1000	0.03500000	0.02503747	0.04800646
8	profile	35	1000	0.03500000	0.02477809	0.04759929
9	lrt	35	1000	0.03500000	0.02477471	0.04759536
10	prop.test	35	1000	0.03500000	0.02485150	0.04886143
11	wilson	35	1000	0.03500000	0.02527226	0.04828662

Математика

- оптимизация: optim, пакет Ip_solve, пакет quadprog
- алгебра: expm, Matrix, mstate
- анализ: integrate, cubature, caracas
- теория вероятности: actuar, extraDistr, fBasics
- геометрия: geometry, deldir, sf
- взаимодействие со stan для статистического моделирования (MCMC)



Медленные циклы

- динамическое расширение объектов в цикле
- динамическая типизация
- можно писать на C++ через Rcpp

```
> start <- Sys.time()
> res <- c()
> for (i in 1:100000) {
+   res <- c(res, i^2)
+ }
> print(Sys.time() - start)
Time difference of 24.88308 secs
```

```
> cppFunction('
+ NumericVector rcpp_squares(int n) {
+   NumericVector res(n);
+   for(int i = 0; i < n; ++i) {
+     res[i] = pow(i + 1, 2);
+   }
+   return res;
+ }
+')
```

```
> start <- Sys.time();
> res <- numeric(100000)
> for (i in 1:100000) {
+   res[i] <- i^2
+ }
> print(Sys.time() - start)
Time difference of 0.6857431 secs
```

Векторизация

- apply, lapply, sapply, vapply, tapply
- пакет purrr, функция map
- Vectorize
- специализированные пакеты (dplyr, data.table)
- recycling rule



REST


- пакеты httr, httr2
- пакет jsonlite
- можно работать с разными видами аутентификации
- plumber для создания своего REST api (#*, @get, @post)

```
> res <- POST(  
+   url = "https://example.com",  
+   add_headers("X-API-Key" = "secret123"),  
+   body = list(name = "Иван", age = 30),  
+   encode = "json"  
+ )
```

```
> res <- request("https://example.com") %>%  
+   req_method("POST") %>%  
+   req_headers("X-API-Key" = "secret123") %>%  
+   req_body_json(list(name = "Иван", age = 30)) %>%  
+   req_retry(max_tries = 3) %>%  
+   req_perform()
```


Работа с БД

- RSQLite
- RPostgres
- odbc
- mongolite
- sparklyr
- RClickhouse
- redux (для Redis)
- RGreenplum
- dbplyr как dplyr, только с БД



Временные ряды

- регулярные ряды (ts)
- случайные процессы (xts)
- auto.arima
- пакет tseries
- пакеты forecast и fable
- пакет prophet
- пакет rugarch



Машинное обучение

- tinymodels (caret)
- mlr3
- catboost (😞😞😞)
- хорошие интерпретируемые модели




Нейронные сети

- ☹️☹️☹️☹️☹️
- nnet, neuralnet
- torch
- keras, tensorflow
- ellmer (LLM)
- ragnar (RAG)
- vitals (llm-as-a-judge)
- для чего-нибудь серьёзного
вроде GigaAM Это остаётся
вызов python-моделей через
reticulate




Причинно следственный анализ

- 😊😊😊😊😊
- выравнивание MatchIt, Weight
- grf, causalToolbox
- causalImpact
- ggdag, daggity
- lmtest (Granger Causality)



CRAN

- Comprehensive R Archive Network
- жёсткая модерация
- авто-тесты на всех ОС
- все последние версии пакетов на CRAN совместимы между собой
- catboost (☹☹☹)



Выводы

Есть смысл использовать R для:

- статистики и статистического моделирования
- интерпретируемых моделей и причинно-следственного анализа
- визуализации исследований
- в науке

Есть смысл использовать Maple для символьных вычислений.

Есть смысл использовать MATLAB для моделирования сложных процессов.

Оставить обратную связь по митапу



Осипов Алексей



aosipov@usetech.ru



[@id22eb924caea242f69bacc91d45](https://t.me/@id22eb924caea242f69bacc91d45)