




Как сделать умный поиск?

Алексей Осипов

О чем митап

1. Что такое умный поиск?
2. Умный поиск по собственной базе
3. Умный поиск в поисковых движках
4. Умный поиск в ZAVODIT



Что такое умный поиск?

4

- У нас есть БД с документами
- На входе текст в свободной форме
- Надо найти наиболее релевантные документы
- Надо сгенерировать ответ на их основе

Что умеет умный поиск

- ✓ Понимает опечатки ("кросовки" → "кроссовки")
- ✓ Знает синонимы ("телефон" = "смартфон")
- ✓ Понимает намерение ("что-то теплое" → куртки, свитера)
- ✓ Учитывает контекст (время года, предпочтения)
- ✓ Учится на каждом запросе

Умный поиск работает как персональный помощник, который всегда находит нужный товар

Что такое RAG?

5

- Генерация с дополненной выборкой
- У нас есть LLM, которая может давать ответы
- Надо найти для неё данные по базе и предоставить их ей.





Схема RAG

6




Ретривер
Генератор
Этап обучения
Этап оценки

Роль ретривера

7


- Нахождение релевантных документов
- Быстрый первичный отсев
- Реранкер с более точным отсевом



Роль генератора

8


- Активное использование LLM
- Сформировать ответ пользователю на основе найденного
- Сделать финальное ранжирование ответов



Роль остальных блоков

9



- Блок оценки для мониторинга
- Блок обратной связи, чтобы подстроиться под пользователя
- Реранкер, чтобы максимально учесть данные для обучения



Как оценивать релевантность?

10

- Точное совпадение и частоты: TFIDF, Jaccard, строковые метрики
- По смыслу: эмбединги
- Специальная модель (бустинг, нейронные сети, сложные нейронные сети)
- Гибрид



БД для RAG

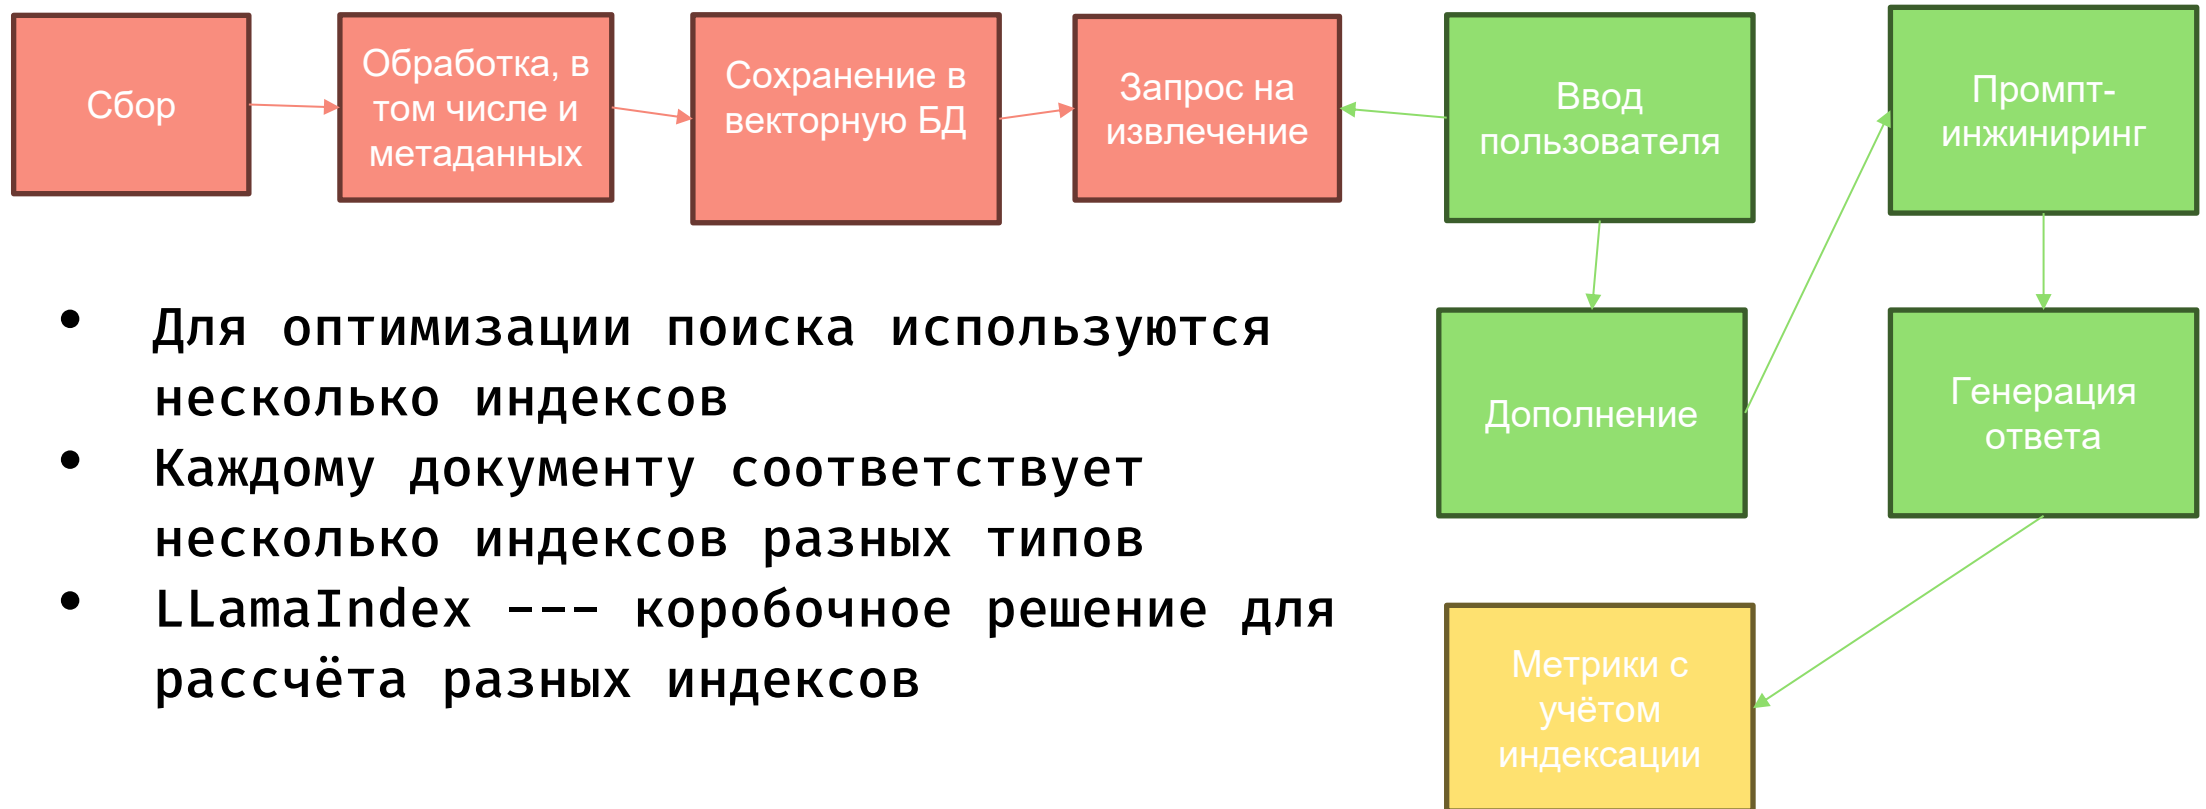
11

- Векторная БД --- БД для оптимального вычисления и хранения эмбедингов
- Векторная БД оптимизирована для поиск по сходству
- Можно фильтровать по метаданным в гибридном подходе
- Примеры векторных БД: Deep Lake, Pinecone, ChromaDB, Pgvector для PostgreSQL, RediSearch для Redis



Индексированный RAG

12




- Для оптимизации поиска используются несколько индексов
- Каждому документу соответствует несколько индексов разных типов
- LlamaIndex --- коробочное решение для расчёта разных индексов

Ретривер
Генератор
Этап оценки

Мультимодальный RAG

13


- Примеры модальностей: текст, изображение, аудио, музыка, видео
- Можно считать эмбединги разных модальностей и сравнивать их (CLIP)
- Можно использовать мультимодальную LLM



Адаптивный RAG

14

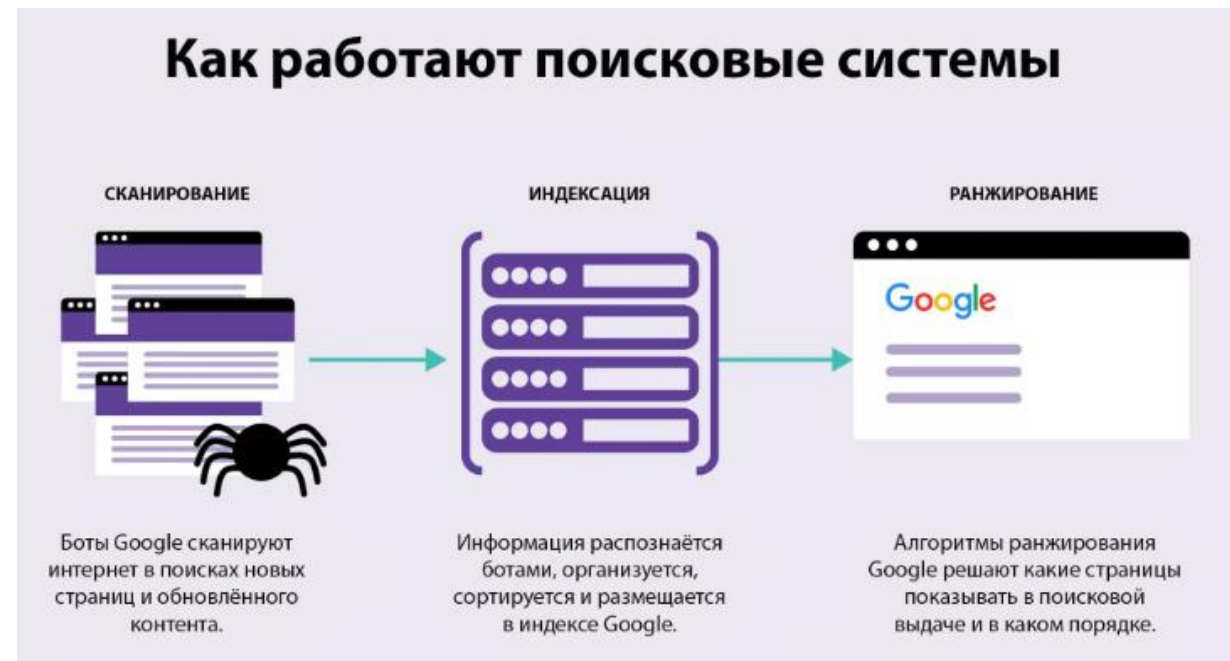
- Учёт обратной связи эксперта/пользователя
- Обратная связь может влиять на выбор режима ретривера (не используем то, что не работает)
- Обратная связь может влиять на режим генератора



Задача поисковых сайтов

16


- Предоставлять отранжированный список документов по запросу в свободной форме
- Учитывать авторитетность
- Учитывать предпочтения пользователя, региональные запросы
- Работа с различным контентом, мультимодальность



Google PageRank

17


- Автор: Larry Page, 1997 год
- Алгоритм определения ценности конкретной страницы
- Смотрим на количество и качество ссылок на страницу
- Страница авторитет, если на неё ссылаются авторитеты
- Основан на теории Марковских процессов (случайное блуждание по графу)
- PageRank --- это что-то вроде вероятности посетить в какой-то момент страницу
- В начале это был алгоритм ранжирования Google, сейчас это один из сотен сигналов



Yandex PFound

18

- Автор: Максим Гурбин, 2009
- Метрика ранжирования
- Вероятность просмотра страницы и вероятность релевантности страницы
- Затухание вероятности просмотра в зависимости от позиции в ранжировании
- Стандарт для оценки ранжирования в Яндексе



Поиск Google: история

19


- PageRank, 1998–2010
- Борьба с низкокачественным контентом и манипуляциями, переход к семантическому поиску, 2011–2014
- RankBrain с эмбедингами (намерение пользователя), E-E-A-T (опыт, экспертность, авторитетность, доверие), 2015–2018
- Трансформеры (BERT) и LLM (Gemini), 2019–по н.в.



Поиск Yandex: история

20


- Ключевые слова и ссылки, 1997–2008
- PFound, MatrixNet (прародитель CatBoost), 2009–2015
- Использование многоруких бандитов, борьба с манипуляциями, 2014–2015
- Трансформеры (YATU) и LLM (YandexGPT), 2016–по н.в.



Поиск Google: особенности

21

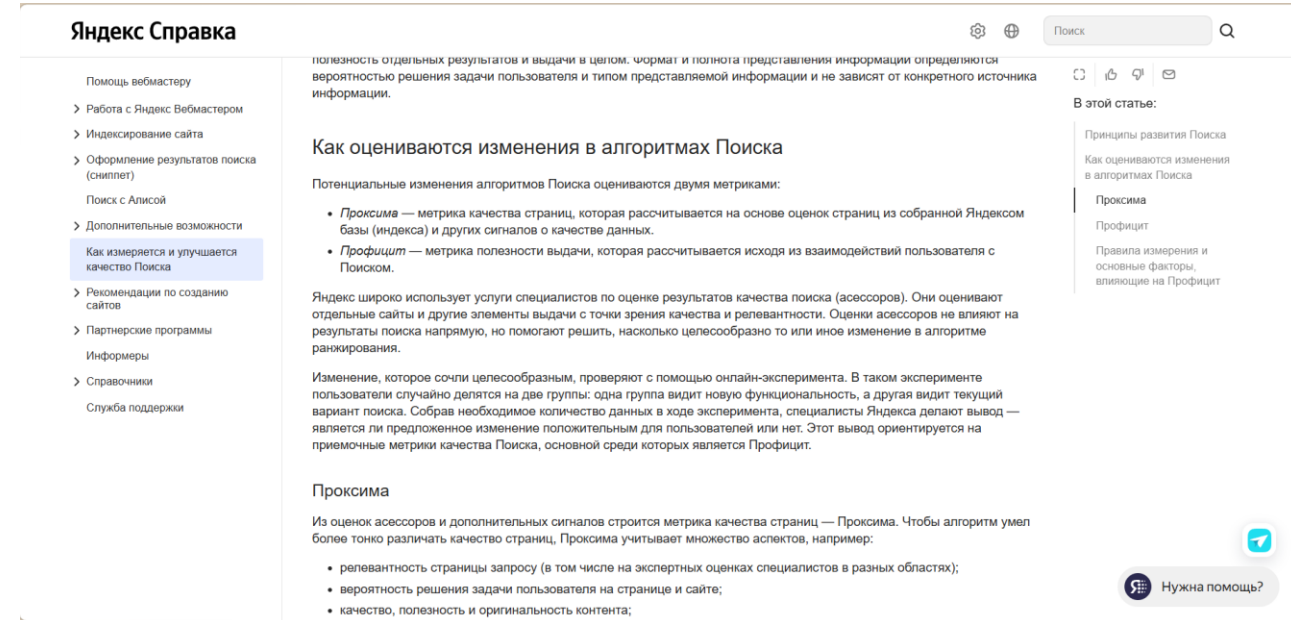
- Ставка на авторитет страницы (E-E-A-T)
- Использование трансформеров и LLM
- Важность мобильных версий сайтов
- Плохо учитывает региональные особенности
- Гораздо лучше подходит для пользователей-исследователей
- Есть регулярно обновляемый гигантский документ про то, как устроен поиск



Поиск Yandex: особенности

22

- Учёт геозависимости
- Важны клики, важно, чтобы пользователь долго не уходил, важно, чтобы пользователь прекратил искать (Профицит)
- CatBoost, PFound
- Использование трансформеров и LLM
- Proxima (надёжность сайта)
- Чтобы понять, как устроены некоторые важные части поиска вроде Профицит или Проксима, надо идти работать в Яндекс



ZAVODIT: постановка задачи

23

- Динамический индексированный гибридный RAG
- У нас есть несколько баз резюме кандидатов (300 тысяч человек).
- Мы хотим искать кандидатов по тексту в свободной форме
- Данные обновляются в течение дня
- Важна интерпретация
- Важно распарсить резюме для визуализации

Корпоративный экзорцист

Опыт работы: От 3 до 6 лет

Полная занятость

График: 5/2

Рабочие часы: 8

Формат работы: на месте работодателя

93 человека
уже откликнулось



25 человек
сейчас смотрят



сотрудников, включая, но не ограничиваясь:

- Демоны неправильных методических подходов;
- Бесы научно необоснованных решений;
- Духи shadow IT и несанкционированного ПО;
- Призраки неэффективной отчетности (Google Sheets, Excel-ад);
- Демоны неструктурированных данных и хаотичного документооборота;


- Глубокое понимание психологии сотрудников IT-компаний;
- Мастерство в выявлении источников неэффективности и их устранении;
- Способность проводить сеансы "экзорцизма" как индивидуально, так и для целых отделов;
- Знание современных методологий разработки, управления проектами и организации труда;
- Харизма и умение убедить даже самых скептически настроенных сотрудников.

Мы предлагаем:

- Уникальную возможность изменить корпоративную культуру изнутри;
- Полную поддержку руководства в борьбе с "демонами" неэффективности;
- Конкурентную зарплату и бонусы за каждого "изгнанного демона";
- Гибкий график ("демоны" не соблюдают рабочее время);
- Комплект корпоративных "священных" артефактов для проведения ритуалов.

ZAVODIT: схема поиска

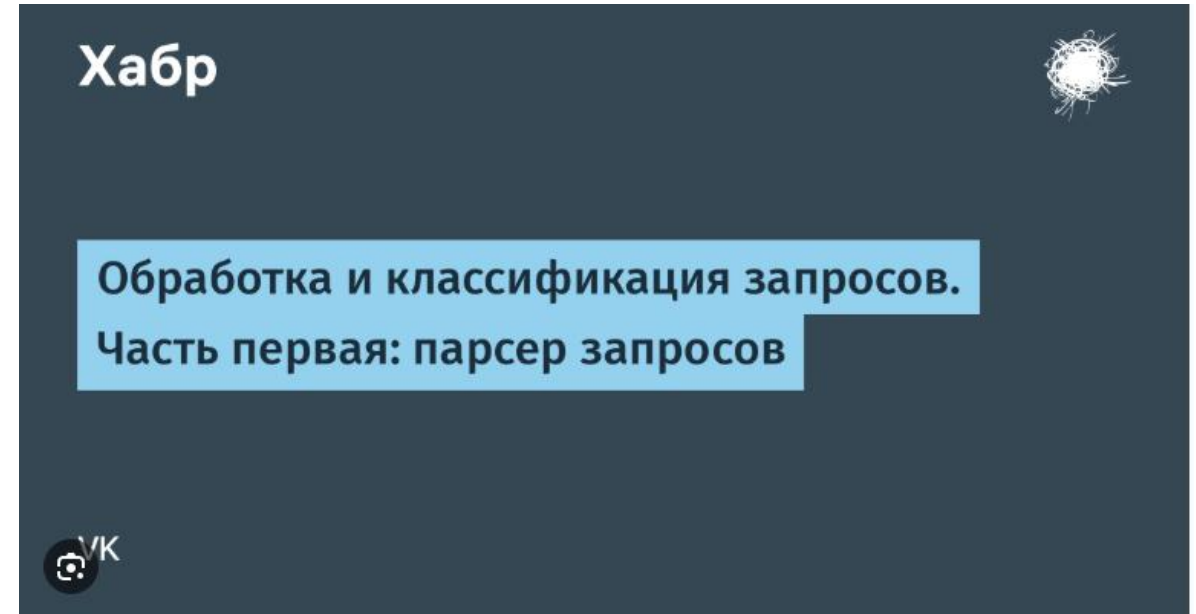
24



Парсер запроса

25


- Модель определения типа запроса (вакансия или резюме)
- Выделяем жёсткие требования: возраст, локация, компании, опыт работы в годах, уровень образования
- Выделяем должность
- Выделяем остальные требования



Парсер резюме

26

- Структурированные резюме (хантфлоу, хэдли) и свободные резюме (хэдхантер, произвольное)
- Модель определения типа резюме
- Выделение возраста, локации, опыта работы в годах, навыков из секции Навыки и из всего резюме
- Выделение остальных полей (несколько десятков)
- Использование переводчика



БД для поиска


27

- Redis с RediSearch и RedisJSON
- Мы загружаем json-ы резюме с индексацией по полям для поиска
- Есть индексация по эмбедингам для должности (векторный поиск)
- Эмбединги для навыков и эмбединги для резюме хранятся в обычном Redis



Динамическая подготовка базы

28



Ретривер в ZAVODIT

29

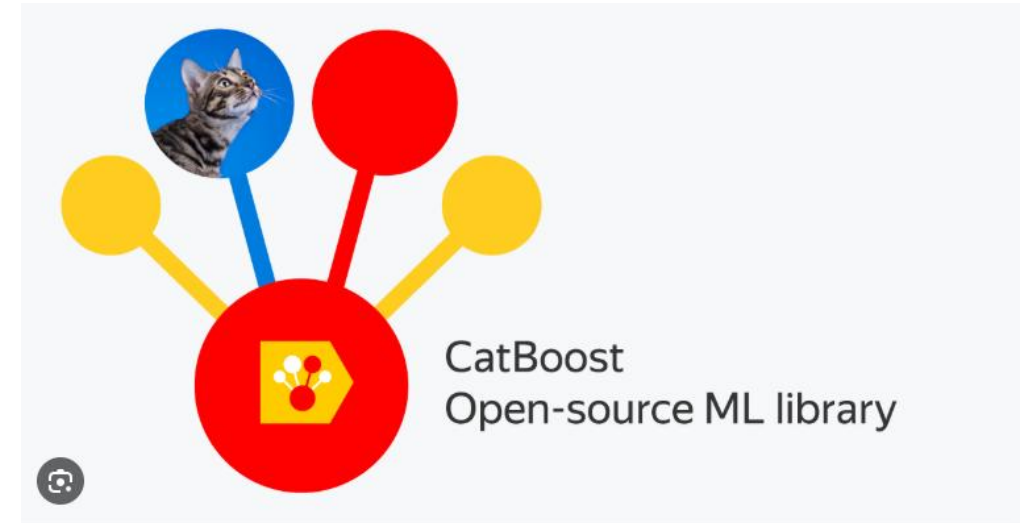
- Задача: понизить число кандидатов с 500 тысяч до 1 тысячи
- Применяем жёсткую фильтрацию (метаданные в Redis)
- Применяем фильтрацию по эмбедингу должности
- Для поиска близкого резюме просто смотрим на эмбединги



Реранкер в ZAVODIT

30

- Задача: Выбрать 100 кандидатов из 1000 и отранжировать их
- Смотрим на матчинг навыков и требований вакансии
- Смотрим отдельно на навыки из Навыки и навыки из резюме
- Смотрим на точные совпадения и на эмбединги
- Используем CatBoost для ранжирования




Генератор в ZAVODIT

31

- Поясняем, почему кандидат подходит, а почему не совсем
- Есть часть, ответственная за скоры
- Есть часть, ответственная за вольную интерпретацию LLM

Результаты поиска > Антон Завьялов



77%

Специализация
Senior Java developer

Контакты
Телефон не указан

Местоположение
Санкт-Петербург

Занятость и график работы

Логика расчёта: score = 77, так как score_job_title = 95, score_skills = 66, score_skills_from_experience = 64, а score = (score_job_title + score_skills + score_skills_from_experience) / 2 / 2.5).
Интерпретация LLM: Вот анализ кандидата: 1. **Должность**: Senior Java .Net разработчик. 2. **Требования для должности**: - Понимание принципов микросервисной архитектуры - Строеие мониторинга и алертинга - Языки .NET и Java - CI CD процессы - Крупный федеральный ритейлер - Kafka - Базовые знания контейнеризации - REST API - БД MongoDB и MS SQL 3. **Навыки кандидата**: Java, Jenkins, Docker, Agile, CI CD, Elasticsearch, GitLab, Kubernetes, MongoDB, Spring, Boot, REST, API, PostgreSQL, Spring, Data, TDD, Spring, Camunda, BPMN, Разработка ПО, Apache, Kafka, Spring, Cloud, Apache, Maven, GitLab, CI, Mockito, Spring, Security, JUnit, DDD, Liquibase, RabbitMQ, Hibernate, ActiveMQ. 4. **Подтвержденные навыки**: Java, Jenkins, Docker, CI CD, GitLab, MongoDB, Spring, API, Spring, Data, Spring, Camunda, BPMN, Kafka, Spring, Cloud, GitLab, CI, Spring, Security. 5. **Опыт работы**: 13 лет. Навыки кандидата в целом соответствуют требованиям для этой должности, но есть несколько ключевых моментов: - Кандидат имеет опыт работы с Java и .NET, а также понимание принципов микросервисной архитектуры. Однако он не подтвердил опыта работы с языками .NET. - Он знает CI/CD-процессы, контейнеризацию (Docker), REST API и БД MongoDB и MS SQL. - В списке подтвержденных навыков нет упоминания о Spring Boot или Apache Kafka. Однако он подтвердил знание Spring, Camunda, BPMN, Kafka и Spring Cloud. - Он имеет опыт работы с Agile и CI/CD-процессами. Оценка соответствия данной должности составляет 77 из 100. Возможно, это связано с тем, что кандидат не подтвердил опыта работы с языками .NET и Spring Boot, а также не упомянул о знании мониторинга и алертинга, хотя он знает CI/CD-процессы. Также стоит отметить, что опыт работы кандидата

Статус
Отказ
Отказ
Всё 4 статусов

Задеплоил обновление на Pandora (ИИ prod):

Выводы

32

- Для поиска по собственной базе есть смысл использовать RAG
- Нужна векторная БД
- Поисковые сайты решают другие задачи, но общие места всё равно есть
- Поиск в ZAVODIT --- динамический индексированный гибридный RAG с нетривиальными улучшениями, специфичными для нашей задачи

Git, Gittlab, CI, Gittlab runner, Bash, Администрирование серверов, DevOps, 7, Предприятие, AWS, IIS, NAT, DNS, Ansible, PostgreSQL, HTML, Docker, Nginx, CSS, Python, VPN, Локальные сети, и, Kubernetes, 1С, их, Ориентация в программных платформах, Exchange, GittLab, конфигурациях, Linux, Docker-compose, 8, IPT ables Debian OpenVPN, KVM

+7 965 7909106

Локация не указана Нет данных

 **Дмитрий Кугаевский, 31 год**
Нет данных и статусов

DevOps Engineer 0.0 P

6 лет, 1 месяц

SQL, Nexus, Git, CI, Gittlab, Jenkins, Bash, Администрирование серверов, Prometheus, DevOps, IDE, Zabbix, Ansible, Nginx, Docker, CI/CD, Grafana, Python, Computer troubleshooting, Kubernetes, Asterisk, GittLab, Maven, Linux, Selenium, Groovy

+7 999 0405319

Санкт-Петербург Нет данных

 **Михаил Тарасов, 34 года**
Нет данных и статусов

DevOps Инженер 3П не указана

11 лет, 10 месяцев

SQL, Git, Gittlab, CI, Jenkins, Автоматизация процессов, Bash, Администрирование серверов, Виртуализация, Prometheus, MongoDB, AWS, Мониторинг, Ansible, PostgreSQL, Docker, Nginx, Grafana, Python, Elasticsearch, Helm, ELK, Kubernetes, Rancher, AZURE GCP, Linux, Terraform, Groovy

+7 923 2251341

Локация не указана Нет данных

< 1 2 3 4 5 6 ... 10 >

Оставить обратную связь по митапу



Осипов Алексей



aosipov@usetech.ru



[@id22eb924caea242f69bacc91d45](https://t.me/@id22eb924caea242f69bacc91d45)